

# פרויקט גמר – אינטרקציית אדם סוכן

האם ניתן לחזות התנהגות אנשים במשחקים לאור החלטותיהם במשחקים קודמים?



מגישים

ישראלה מגירא, ת.ז 209015817

תמיר שמואלי, ת.ז 207021460

## מבוא

השאלה הנבחנת בפרויקט זה הינה האם ניתן לחזות התנהגות אנשים במשחקים לאור החלטותיהם במשחקים קודמים, בפרט במשחקי "תן" ו-"קח". נבחן את השאלה באמצעות נתונים שנלקחו מהמאמר "An exploration of the motivational basis of take-some and give-some<sup>1</sup>games".

במאמר נבדקו בחירות של 229 משתתפים ב-4 משחקים:

- Dictator game – משחק "תן" עם שני שחקנים. השחקן הנבדק צריך לבחור כמה כסף לתת למשתתף השני, בין 0 ל-100.
- Bandit game – משחק "קח" עם שני שחקנים. השחקן הנבדק צריך לבחור כמה כסף לקחת מהמשתתף השני, בין 0 ל-100.
- Public good dilemma game – משחק "תן" עם מספר מרובה של משתתפים. השחקן הנבדק צריך לבחור כמה כסף לתת לקבוצה, בין 0 ל-40. כאשר בסוף המשחק הכסף שנשאר בקבוצה מחולק שווה בשווה בין כולם ומוכפל פי 2.5.
- Common good dilemma – משחק "קח" עם מספר מרובה של משתתפים. השחקן הנבדק צריך לבחור כמה כסף לקחת מקבוצה, בין 0 ל-40. כאשר בסוף המשחק הכסף שנשאר בקבוצה מחולק שווה בשווה בין כולם ומוכפל פי 2.5.

בחרנו לחזות את בחירות השחקנים במשחק Dictator באמצעות בחירותיהם במשחקים האחרים, או בחלק מהם.

## שיטות

### Expert driven – שיווי משקל נאש

ראשית, ניסינו לגשת למשימת החיזוי בגישת expert driven. בפרט, מכיוון שמדובר בבעיה הלקוחה מעולם תורת המשחקים, השתמשנו בשיווי משקל נאש כדי לחזות את בחירת השחקנים. מכיוון שבני אדם אינם רציונלים, מיד ראינו שחיזוי טריוויאלי שיתעלם מהנתונים לחלוטין, ויניח בחירה רציונלית, יהיה שגוי בתכלית (למעשה, בודדים בחרו בבחירה הרציונלית).

לכן, בחרנו להשתמש בשיווי משקל נאש כנקודת ייחוס בחיזוי שביצענו. ביצענו חיזוי של תוצאות משחק dictator באמצעות תוצאות משחק bandit, שכן הם משחקים בעלי מאפיינים דומים (טווח ערכים זהה, שני משתתפים). במשחק bandit, נקודת שיווי משקל נאש, שתביא למקסימום תועלת, תהייה לקחת את כל ה-100. באופן דומה, במשחק dictator, נקודת שיווי משקל נאש תהייה לתת 0.

החיזוי התבצע באופן הבא: אם אדם בחר בבחירה הרציונלית bandit, הנחנו כי יבחר בבחירה הרציונלית גם dictator. לגבי היתר, הנחנו כי הסטייה מהרציונליות תישאר זהה, למשל:

- אם אדם פלוגי בחר לקחת 80 במשחק bandit חזינו כי יתן 20 במשחק dictator.
- אם אדם אלמוני בחר לקחת 50 במשחק bandit חזינו כי יתן 50 במשחק dictator.

### Data driven

בהמשך, ביצענו חיזוי שמתבסס בעיקר על הנתונים (ומתעלם משיווי משקל נאש), במספר שיטות - בחרנו להציג בפרויקט שתיים מהן. נציין, כי במודלים שביצענו ראינו שהבחירה במשחק common good dilemma לא מסייעת רבות בחיזוי, ולכן לא השתמשנו בנתונים ממשחק זה בשתי השיטות הנבחרות. כמו כן, כדי לסייע בהתאמה בין הנתונים במשחקים השונים, הצגנו את הבחירות מנק' המבט המתאימה למשחק dictator, כלומר את סכום הכסף שהמשתתף משאיר ליתר השחקנים (למשל במשחק Bandit אם המשתתף בחר לקחת 40, הערך שהוצג במודל היה 60).

### גרסיה לינארית

בשיטה זו, אנו מניחים כי מתקיים קשר לינארי בין הבחירה במשחק dictator לבין הבחירה במשחקים הקודמים. כלומר אם נסמן ב-D את הבחירה במשחק Dictator, ב-P את הבחירה במשחק public good dilemma, וב-B את הבחירה במשחק Bandit, אז המודל מניח:

$$D = b_0 + b_1 * B + b_2 * P$$

ואז מתאים לנתונים  $b_0$ ,  $b_1$ ,  $b_2$  שיביאו למינימום את סכום הטעויות הריבועיות.

לאחר הרצת המודל על הנתונים, התקבלה הנוסחה הבאה:

$$D = 10.5767 + 0.5297 * P + 0.3358 * B$$

## טבלת החלטות

טבלת החלטות, היא מודל שמאפשר לחזות את המשתנה הרצוי, באמצעות חלוקת המשתנים המסבירים לטווחי ערכים. כלומר, בניגוד למודל הרגרסיה הלינארית, שמתאים מקדם קבוע בין המשתנים המסבירים למשתנה הנחזה, מודל זה מאפשר חלוקה קטגוריאלית של המשתנים המסבירים. תוצאת המודל היא טבלה של כללים, שמתאימים לכל זוג טווחי ערכים של המשתנים המסבירים, ערך של המשתנה הנחזה.


במודל טבלת ההחלטות התקבלו כללים רבים. לדוגמה, לגבי אדם שבחר בין 24 ל-28 במשחק public good dilemma וגם בחר בין 70 ל-80 במשחק bandit, המודל חוזה שיבחר 40 במשחק dictator. לטבלת הכללים המלאה, ראה נספח.

## דיון ומסקנות


ראשית, נציג השוואה בין השיטות השונות מבחינת טיב החיזוי:

טבלת החלטות	רגרסיה לינארית	סטייה משיווי משקל	סכום טעויות
1979.21	2895.78	3085	
200	177	159	חיזוי בטווח +20

גרף 1: הערכים שנחזו ע"י מודל הרגרסיה הלינארית (y) כנגד הערכים שנבחרו בפועל במשחק dictator (x)



גרף 2: הערכים שנחזו ע"י מודל טבלת ההחלטות (y) כנגד הערכים שנבחרו בפועל במשחק dictator (x)



ניתן לראות שהחיזוי המיטבי ביותר אליו הגענו בפרויקט זה הינו בשיטת "טבלת החלטות". יתכן שמודל זה עדיף על מודל הרגרסיה הלינארית, שכן הנתונים מאופיינים במספר בחירות שכיחות (כגון

0 ו-50) ובמספר מועט של בחירות אחרות. כלומר, הנתונים לא מספיק מתאימים למודל שמניח רציפות.

עם זאת, גם במודל טבלת ההחלטות קיימות מגבלות. כפי שניתן לראות בטבלת הכללים בנספח, המודל לא התאים בחירה לכל הערכים האפשריים (אלא רק לערכים שנבחרו בפועל ע"י 229 המשתתפים). לכן, המודל לא מסוגל לחזות את הבחירה של משתתף עתידי שיבחר ערך שלא הותאם לו כלל. ניתן להתמודד עם מגבלה זו בעזרת איסוף נתונים נוסף עם מספר גדול יותר של משתתפים.

בפריקט זה, לא הצלחנו להגיע למודל חיזוי מדויק והמודל הטוב ביותר חוזה תוצאה בטווח טעות של 20-+ לגבי 200 מתוך 229 המשתתפים. יתרה מכך, המודל נוצר על סמך תוצאותיהם של 229 המשתתפים ולכן לגבי משתתפים עתידיים, כנראה תתרחש טעות חיזוי גדולה יותר.

תוצאה זו ניתנת להסבר ע"י מאפייניהם השונים של המשחקים ("תן", "קח", זוג משתתפים, משתתפים מרובים). כמו כן, כפי שצוין במאמר<sup>1</sup>, בני אדם מושפעים ממאפיינים רבים (חברתיים ואישיים) ועל כן קשה לצפות את בחירותיהם באופן מדויק, ללא מידע מקדים לגבי מאפיינים אלו. יתרה מכך, אפילו בהינתן מידע לגבי מאפיינים חברתיים ואישיים, המאמר לא הצליח למצוא "כלל אצבע" לגבי כל המשחקים, אלא רק לחלק מהם.

יתכן כי שימוש בכלים מתקדמים יותר של למידת מכונה, או איסוף המבוסס על מספר רב יותר של משתתפים, יסייע בבניית מודל חיזוי מדויק יותר.

## נספח – טבלת ההחלטות לחיזוי הבחירה ב Dictator Game

Rules:

PGDG.CHOICE BG.CHOICE.R DG.CHOICE

```

=====
' (28-32] ' ' (90-inf) ' 66.66666666666667
' (-inf-4] ' ' (90-inf) ' 16.666666666666668
' (32-36] ' ' (90-inf) ' 27.5
' (12-16] ' ' (90-inf) ' 50.0
' (36-inf) ' ' (90-inf) ' 61.55555555555556
' (16-20] ' ' (80-90] ' 50.0
' (36-inf) ' ' (80-90] ' 50.0
' (24-28] ' ' (80-90] ' 75.0
' (24-28] ' ' (70-80] ' 40.0
' (16-20] ' ' (70-80] ' 50.0
' (28-32] ' ' (70-80] ' 30.0
' (36-inf) ' ' (70-80] ' 46.142857142857146
' (32-36] ' ' (70-80] ' 50.0
' (4-8] ' ' (60-70] ' 30.0
' (28-32] ' ' (60-70] ' 50.0
' (32-36] ' ' (60-70] ' 45.0
' (12-16] ' ' (50-60] ' 9.0
' (28-32] ' ' (50-60] ' 51.5
' (8-12] ' ' (50-60] ' 40.0
' (16-20] ' ' (50-60] ' 35.0
' (36-inf) ' ' (50-60] ' 47.5
' (-inf-4] ' ' (40-50] ' 51.0
' (32-36] ' ' (40-50] ' 50.0

' (4-8] ' ' (40-50] ' 45.0
' (20-24] ' ' (40-50] ' 40.0
' (24-28] ' ' (40-50] ' 50.0
' (12-16] ' ' (40-50] ' 43.57142857142857
' (28-32] ' ' (40-50] ' 48.09090909090909
' (16-20] ' ' (40-50] ' 43.65
' (8-12] ' ' (40-50] ' 39.1
' (36-inf) ' ' (40-50] ' 49.13636363636363
' (28-32] ' ' (30-40] ' 100.0
' (36-inf) ' ' (30-40] ' 15.0
' (12-16] ' ' (30-40] ' 40.0
' (16-20] ' ' (30-40] ' 35.5
' (8-12] ' ' (20-30] ' 1.0
' (24-28] ' ' (20-30] ' 46.0
' (16-20] ' ' (20-30] ' 45.0
' (36-inf) ' ' (20-30] ' 50.0
' (24-28] ' ' (10-20] ' 19.0
' (36-inf) ' ' (10-20] ' 75.0
' (-inf-4] ' ' (-inf-10] ' 2.25
' (8-12] ' ' (-inf-10] ' 5.0
' (4-8] ' ' (-inf-10] ' 6.0
' (36-inf) ' ' (-inf-10] ' 22.333333333333332
' (16-20] ' ' (-inf-10] ' 11.1
=====

```